

Effet du RLHF sur la direction de la mauvaise calibration

